赖禹欣

yuxin.lai@outlook.com · (+86) 152-9782-8468 · yuxinlai.com

教育背景

香港中文大学 2026 年 8 月 – 至今

计算机科学与工程 博士在读　导师：徐宏（Hong Xu）　研究方向：AI Infra

华中科技大学 2022 年 9 月 – 2026 年 6 月

计算机科学与技术 工学学士　加权成绩：94.2 / 100　GPA：4.83 / 5.00　专业排名：**4 / 314（前 1.3%）**

论文发表

KunServe: **Parameter-centric Memory Management for Efficient Memory Overloading Handling in LLM Serving**

Rongxin Cheng, **Yuxin Lai**, Xingda Wei, Rong Chen, Haibo Chen　***EuroSys'26***（CCF-A） [Paper] [Code]

实习与科研经历

字节跳动 Seed Infra 2025 年 11 月 – 至今

研究实习生

Bitwise 精度验证框架

- 主导开发分布式训练 bitwise 精度验证框架：针对浮点非结合律误差与算子非确定性，设计系统化的数值精度对齐机制，支持跨并行配置的 bitwise 正确性验证。
- 基于 PyTorch 实现低侵入式算子与集合通信原语拦截，低侵入模型业务代码，支持 TP、SP、PP、EP、FSDP 等主流并行及各种预训练优化技术的 bitwise 精度对齐。
- 结合配套的精度对齐 skill 接入 agent，推动框架在实际训练场景落地并融入训练系统迭代流程，累计定位 10+ 起正确性问题，将精度异常排查耗时由数天人工定位缩短至小时级自动定位。

预训练工程优化

- 针对大规模预训练通信与访存瓶颈，参与计算通信 overlap 调度及算子融合优化，隐藏并行通信开销，提升集群训练吞吐与 MFU。
- 开展分布式训练显存优化，结合 SAC、offload 与显存碎片治理降低峰值显存占用，支撑更大批次与长序列扩展。

KunServe: LLM Serving System 2024 年 7 月 – 2025 年 5 月

科研实习生　导师：魏星达、陈海波（上海交通大学 **IPADS** 实验室）

- 研发首个以参数为中心的 LLM 推理系统：在突发流量下按需丢弃跨实例冗余模型权重以即时释放显存消除排队，并基于 CUDA 虚拟内存管理 API 实现零内核侵入的参数与 KVCache 物理显存动态复用。
- 负责系统核心代码实现及多机多卡性能验证评测：结合跨实例流水线并行协同执行、激活优先的协同网络传输及前瞻微批调度消除气泡，较 vLLM、Llumnix、InferCept 最高降低 **72.2**× 尾延迟（P99 TTFT）并减少 7.2%–12.8% SLO 违约。

DNN Checkpoint 2023 年 9 月 – 2023 年 11 月

科研实习生　导师：华宇（华中科技大学）

- 搭建多卡分布式深度学习训练容错实验平台，复现多级存储（GPU–DRAM–NVMe）分层异步 Checkpoint 与软硬件协同持久化方案，剖析检查点序列化及 I/O 带宽争用对训练吞吐的影响。

获奖情况

CCF 优秀大学生 2025 年 10 月
国家奖学金（2023–2024 学年度） 2024 年 12 月
国家奖学金（2022–2023 学年度） 2023 年 12 月
全国青少年信息学奥林匹克联赛（NOIP）一等奖 2019 年 12 月
蓝桥杯全国软件和信息技术专业人才大赛全国总决赛一等奖 2024 年 6 月
CCF 大学生计算机系统与程序设计竞赛（CCSP）铜奖 2023 年 10 月

专业技能

- **机器学习系统**：熟悉大模型分布式训练与推理服务系统研发；熟悉 PyTorch、CUDA、NCCL 等。
- **编程语言与平台**：熟练掌握 Python、C++、Go；熟悉 Linux 系统开发、Docker 与 Kubernetes 集群环境。
- **AI 开发工具**：熟练运用 AI Agent 工具链构建高效编码、调试与自动化测试工作流。
- **语言能力**：英语雅思 7.5（C1 Advanced），具备良好的英文读写与沟通能力。